BORDEAUX YNOV CAMPUS

Les bases des statistiques descriptives

BAPTISTE MOSER - INFO B2-

ANNÉE SCOLAIRE 2025/2026

Objectifs d'apprentissage

À la fin de ce module, vous serez capables de :

Identifier les variables

Distinguer populations, échantillons et types de données (qualitatives, quantitatives).

Résumer un dataset

Calculer et interpréter : moyenne, médiane, mode, écart-type, quartiles.

Visualiser les données

Construire des histogrammes, boxplots, bar charts et scatter plots pertinents.

Interpréter les distributions

Analyser la forme (symétrie, asymétrie) et détecter les valeurs aberrantes (outliers).

Corrélation ≠ Causalité

Distinguer les liens statistiques des relations de cause à effet.

Introduction à l'inférence

Comprendre les concepts d'échantillonnage, de biais et d'intervalle de confiance.

Application Technique

Mettre en pratique ces concepts sur des données réelles avec **Python & pandas**.

Vocabulaire de base

Concepts essentiels pour structurer l'analyse statistique

Population

L'ensemble complet de tous les éléments ou individus qui font l'objet de l'étude (ex: tous les utilisateurs inscrits).

ENSEMBLE GLOBAL

Échantillon

Sous-ensemble observé de la population, sélectionné pour représenter le tout (ex: les logs d'une journée).

SOUS-ENSEMBLE

Observation

Une entité individuelle mesurée au sein de l'échantillon. Correspond à une **ligne** dans une base de données.

LIGNE (ROW)

Variable

Une caractéristique mesurée sur chaque observation (qualitative ou quantitative). Correspond à une **colonne**.

COLONNE (COLUMN)

Attribut / Feature

Terme utilisé en Data Science/ML pour désigner une variable explicative utilisée comme entrée d'un modèle prédictif.

MACHINE LEARNING

Mesure / Indicateur

Valeur calculée ou agrégée à partir des données brutes pour résumer une information (ex: moyenne, taux d'erreur, KPI).

AGRÉGATION

Types de Variables

Classification fondamentale pour choisir les bonnes méthodes d'analyse

Qualitative (Catégorielle)

Décrit une qualité, un état ou une appartenance.

Nominale

Catégories sans ordre intrinsèque. On ne peut pas dire "A > B".

Ordinale

Catégories avec une notion d'ordre ou de hiérarchie claire.

Quantitative (Numérique)

Décrit une quantité mesurable sur laquelle on peut faire des calculs.

Discrète

Valeurs dénombrables, souvent entières (fini ou infini dénombrable).

Continue

Valeurs réelles pouvant prendre une infinité de précisions dans un intervalle.

Exemples Informatiques

QUALITATIVE NOMINALE

Code de statut HTTP

200 OK, 404 Not Found, 500 Error

QUALITATIVE ORDINALE

Niveau de Log

DEBUG < INFO < WARN < ERROR

QUANTITATIVE DISCRÈTE

Métriques d'usage

Nombre de clics, Nb de visiteurs uniques

QUANTITATIVE CONTINUE

Performance système

Latence (34.5 ms), Température CPU (65.2°C)

Statistiques descriptives – Tendance centrale

Résumé de l'information : autour de quelle valeur se regroupent les données ?

Moyenne (Mean)

Sensible aux outliers

Somme des valeurs divisée par leur nombre. C'est le centre de gravité des données. Très influencée par les valeurs extrêmes.

Médiane (Median)

Robuste

Valeur centrale qui sépare l'échantillon en deux groupes de taille égale (50% au-dessus, 50% en dessous). Peu sensible aux extrêmes.

Mode

Catégoriel

Valeur la plus fréquente dans le jeu de données. Seule mesure de tendance centrale utilisable pour les variables nominales.

Conseil Data Science

Pour analyser la **latence réseau**, préférez toujours la **médiane** (ou le percentile 95/99). La moyenne est souvent faussée par quelques requêtes très lentes (timeouts).

analysis.py

```python
# Chargement des logs API
df = pd.read_csv('logs_api.csv')
lat = df['latence_ms']

# 1. Moyenne (Attention aux valeurs extrêmes !)
mean_val = lat.mean()
print(f"Moyenne : {mean_val:.2f} ms")

# 2. Médiane (Plus robuste)
median_val = lat.median()
print(f"Médiane : {median_val:.2f} ms")

# 3. Mode (Valeur la plus fréquente)
mode_val = lat.mode().iloc[0]
print(f"Mode : {mode_val} ms")
```

TERMINAL OUTPUT

```
> Moyenne : 142.50 ms
> Médiane : 45.00 ms
> Mode : 42 ms
```

Statistiques descriptives – Dispersion

Mesure de la variabilité : les données sont-elles étalées ou groupées ?

↔ Étendue (Range)

Simple mais instable

Différence entre le maximum et le minimum. Donne une idée rapide mais dépend uniquement des deux valeurs extrêmes.

Écart-type (Std Dev)

La référence

Racine carrée de la variance. Mesure la dispersion moyenne autour de la moyenne. S'exprime dans la même unité que les données.

IQR (Interquartile Range)

Robuste

Écart interquartile (Q3 - Q1). Concentre les 50% de données centrales. Très résistant aux valeurs aberrantes (outliers).

Interprétation Data

Un **écart-type faible** signifie que les performances sont stables et prévisibles.
Un **écart-type élevé** indique une instabilité (ex: gigue réseau importante).

dispersion.py

```python
lat = df['latence_ms']

# 1. Étendue (Range)
etendue = lat.max() - lat.min()

# 2. Variance & Écart-type (Sample: ddof=1)
var_val = lat.var(ddof=1)
std_val = lat.std(ddof=1)
print(f"Std Dev : {std_val:.2f}")

# 3. Quartiles & IQR
q1 = lat.quantile(0.25)
q3 = lat.quantile(0.75)
iqr = q3 - q1
print(f"IQR : {iqr:.2f}")
print(f"Q1:{q1}, Q3:{q3}")
```

TERMINAL OUTPUT

```
> Std Dev : 45.12 ms
> IQR : 22.50 ms
> Q1: 32.0, Q3: 54.5
```

Visualisations – Histogramme et Boxplot

Deux outils essentiels pour diagnostiquer la distribution des données

1. Histogramme

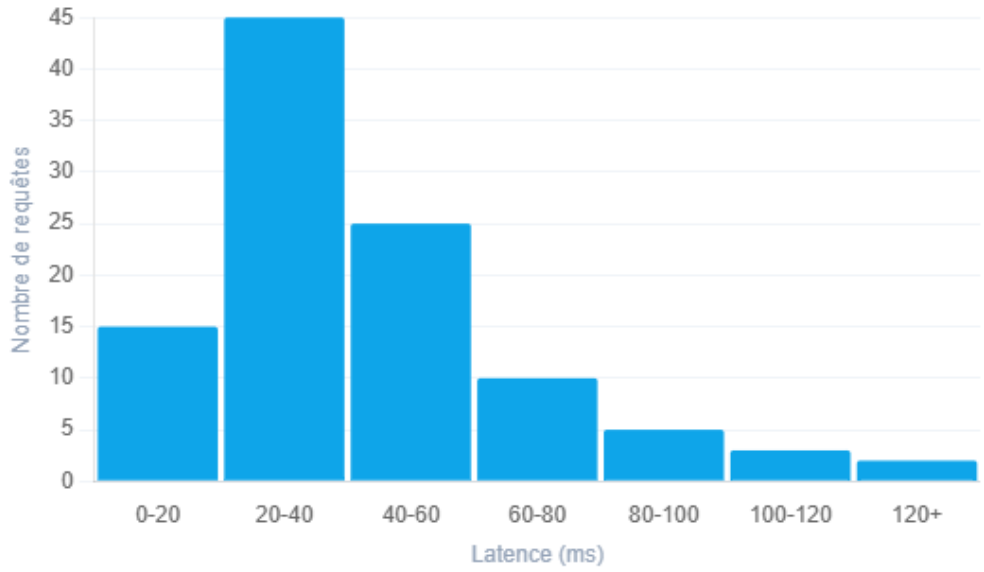

À QUOI ÇA SERT ?

Affiche la **forme** de la distribution. Ici, on observe une "queue" vers la droite (asymétrie positive), typique des temps de latence : beaucoup de requêtes rapides, quelques-unes très lentes.

2. Boîte à moustaches (Boxplot)

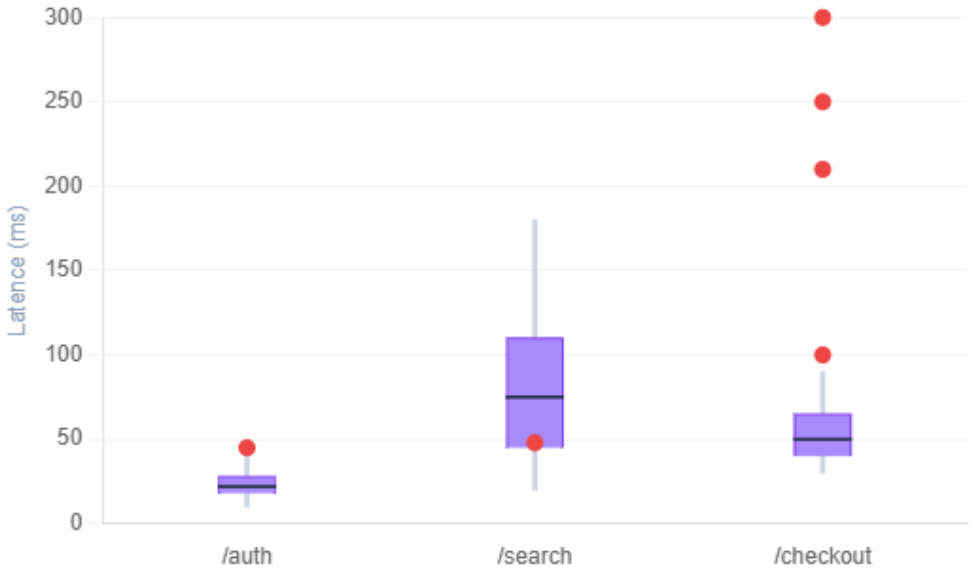

INTERPRÉTATION

La boîte (bleue) contient 50% des données (IQR). La ligne noire est la **médiane**. Les points isolés sont les **outliers**. Idéal pour comparer plusieurs catégories (endpoints).

Visualisations – Bar chart et Scatter plot

Explorer les catégories et les relations entre variables

3. Diagramme en barres

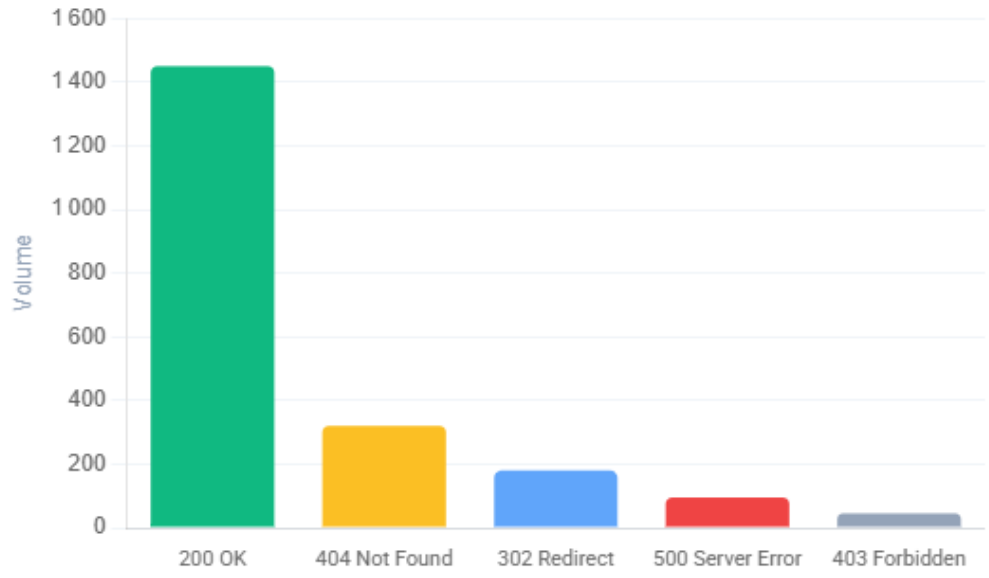

À QUOI ÇA SERT ?

Idéal pour comparer des **variables catégorielles** (qualitatives). Ici, on visualise la fréquence des codes HTTP. Cela permet d'identifier rapidement les classes dominantes (200 OK) et les problèmes fréquents (404, 500).

4. Nuage de points (Scatter)

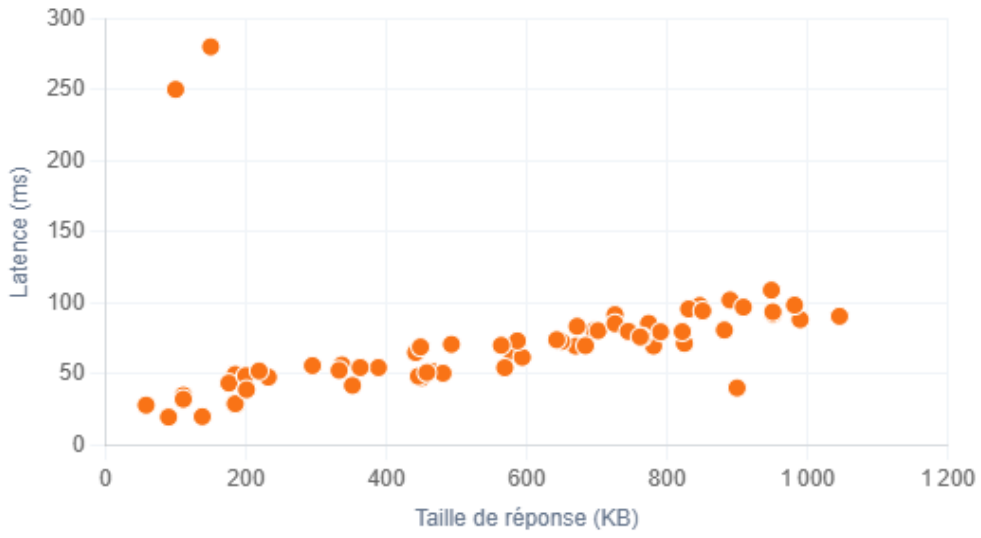

INTERPRÉTATION

Affiche la **relation** entre deux variables quantitatives. On observe une corrélation positive : plus la réponse est volumineuse (axe X), plus la latence augmente (axe Y). Notez les quelques anomalies (outliers) en haut à gauche.

Distribution des Données

Comprendre la forme des données : Symétrie, Asymétrie et Densité

Indicateurs de forme

Skewness — **Coefficient d'asymétrie.**

≈ 0 : Symétrique
> 0 : Queue à droite (positif)
< 0 : Queue à gauche (négatif)

Kurtosis — **Coefficient d'aplatissement.**

Mesure le poids des queues de distribution (présence d'outliers extrêmes).

Types courants en IT

Loi Normale (Gaussienne) — SYMÉTRIQUE

Phénomènes naturels, bruit de fond, erreurs.

Loi Log-Normale — ASYMÉTRIQUE +

Latence, temps de réponse. Bornée à 0, longue traîne vers la droite.

Loi de Poisson — DISCRÈTE

Nombre d'événements par intervalle (ex: requêtes/sec, bugs/jour).

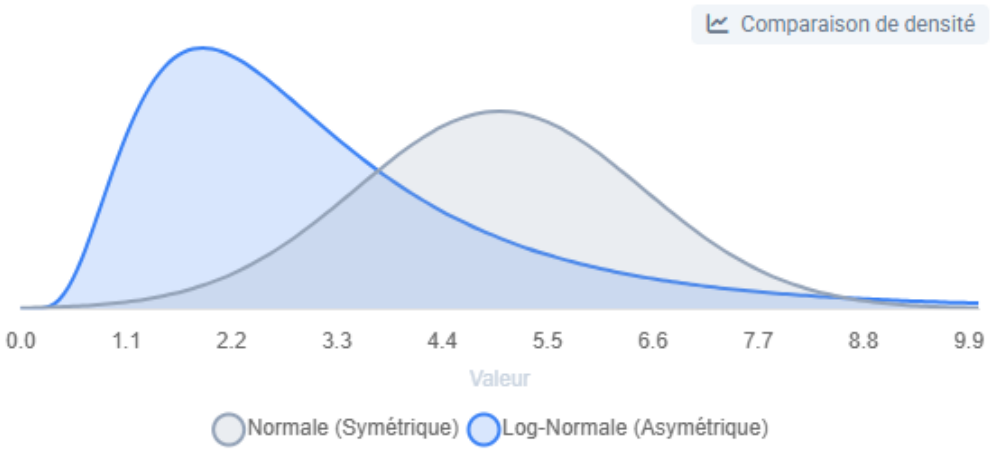

diagnostic_dist.py

```python
import pandas as pd
import seaborn as sns

# 1. Calcul des indicateurs numériques
print(f"Skewness: {df['latence'].skew():.2f}")
print(f"Kurtosis: {df['latence'].kurtosis():.2f}")

# 2. Visualisation avec estimation de densité (KDE)
sns.histplot(data=df, x='latence', kde=True, log_scale=True)
```

Mini-exercice 1 – Statistiques descriptives

5:00 min

Mettez en pratique les mesures de tendance centrale et de dispersion

DATASET : LATENCES API (MS)

```
[ 21, 22, 23, 25, 26, 27, 28, 200]
```

1 Calculer : Moyenne, Médiane, Écart-type (est.)

Moyenne : 46.5 ms **Médiane :** 25.5 ms

⚠ La moyenne est tirée vers le haut par le 200.

2 Quelle mesure est la plus pertinente ?

La Médiane.

Car la distribution est asymétrique avec un outlier (200ms). La moyenne (46.5) ne représente pas la "latence typique" (20-30ms).

3 Interprétation : Où est l'outlier ?

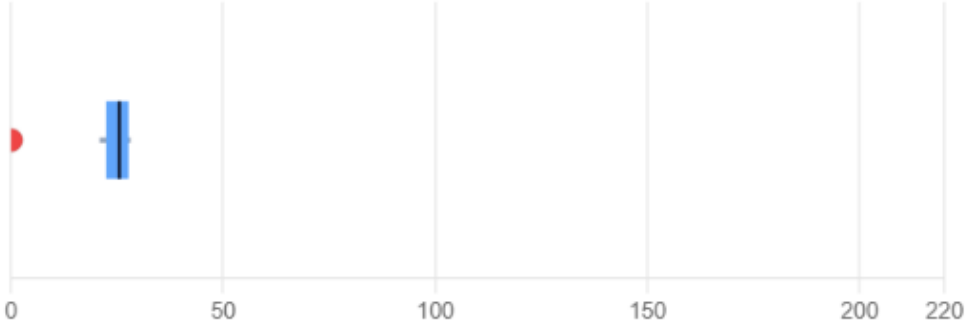

La "boîte" (IQR) est très petite comparée à l'échelle totale.

QCM : Le Code HTTP (ex: 200, 404, 500) est...

- ✓ Quali. Nominale
- Quali. Ordinale
- Quanti. Discrète
- Quanti. Continue

La corrélation

📊 Corrélation : comprendre la relation entre deux variables

🔎 Définition

La corrélation mesure la **force et le sens de la relation** entre deux variables.

📈 Coefficient de corrélation (r)

- $r \in [-1, +1]$
- **r > 0** → relation **positive** (les deux variables augmentent ensemble)
- **r < 0** → relation **négative** (l'une augmente, l'autre diminue)
- **r ≈ 0 → pas de relation linéaire**

📌 Exemples

- Température 🌡️ ↗️ → ventes de glaces 🍦 ↗️ → corrélation **positive**
- Prix 💸 ↗️ → demande 📉 ↘️ → corrélation **négative**

⚠️ Attention

👉 Corrélation ≠ causalité

(Deux variables peuvent être liées sans que l'une cause l'autre)

📊 Calcul de la corrélation (de Pearson)

La corrélation entre deux variables X et Y se calcule avec :

$$r = \frac{\mathrm{Cov}(X,Y)}{\sigma_X \sigma_Y}$$

🧩 Étapes de calcul

1. **Calculer les moyennes**

$$\bar{x} = \text{moyenne de } X, \quad \bar{y} = \text{moyenne de } Y$$

2. **Calculer la covariance**

$$\mathrm{Cov}(X,Y) = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$$

3. **Calculer les écarts-types**

$$\sigma_X, \ \sigma_Y$$

4. **Appliquer la formule**

   👉 On divise la covariance par le produit des écarts-types

DIFFÉRENTS TYPES DE CORRÉLATION ENTRE DEUX VARIABLES

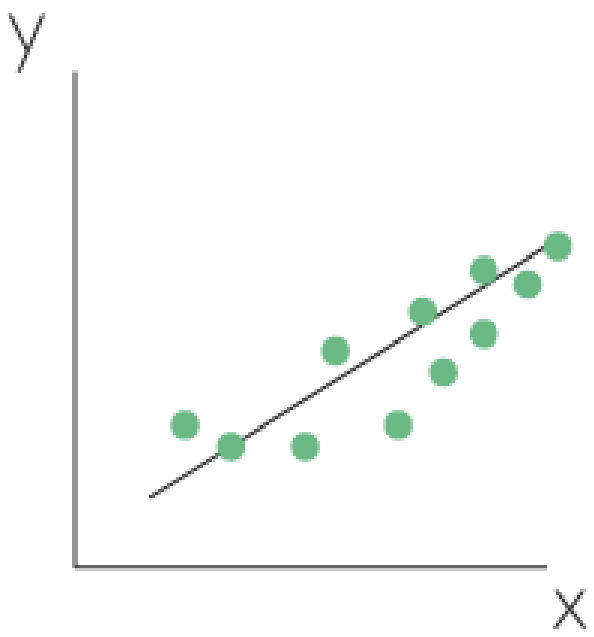

Corrélation positive
entre x et y

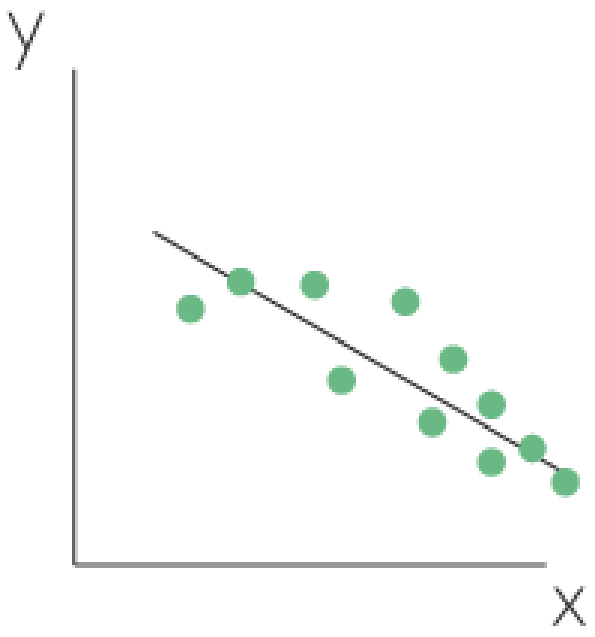

Corrélation négative
entre x et y

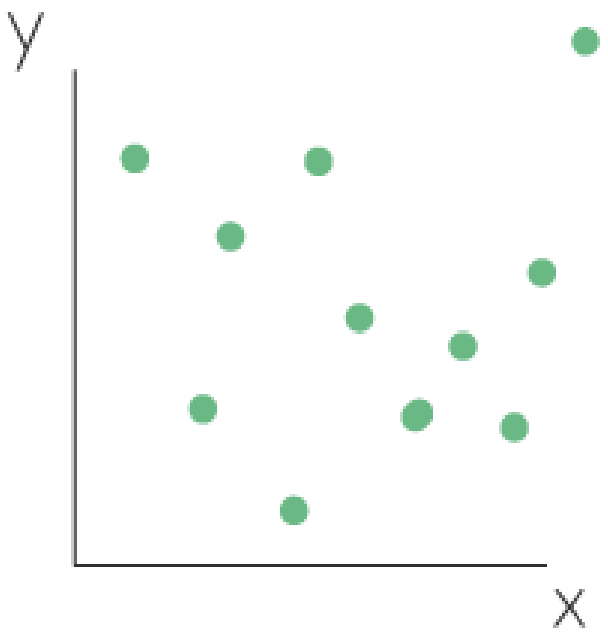

Pas de corrélation
entre x et y

Source : lafinancepourtous.com

Matrices de corrélation

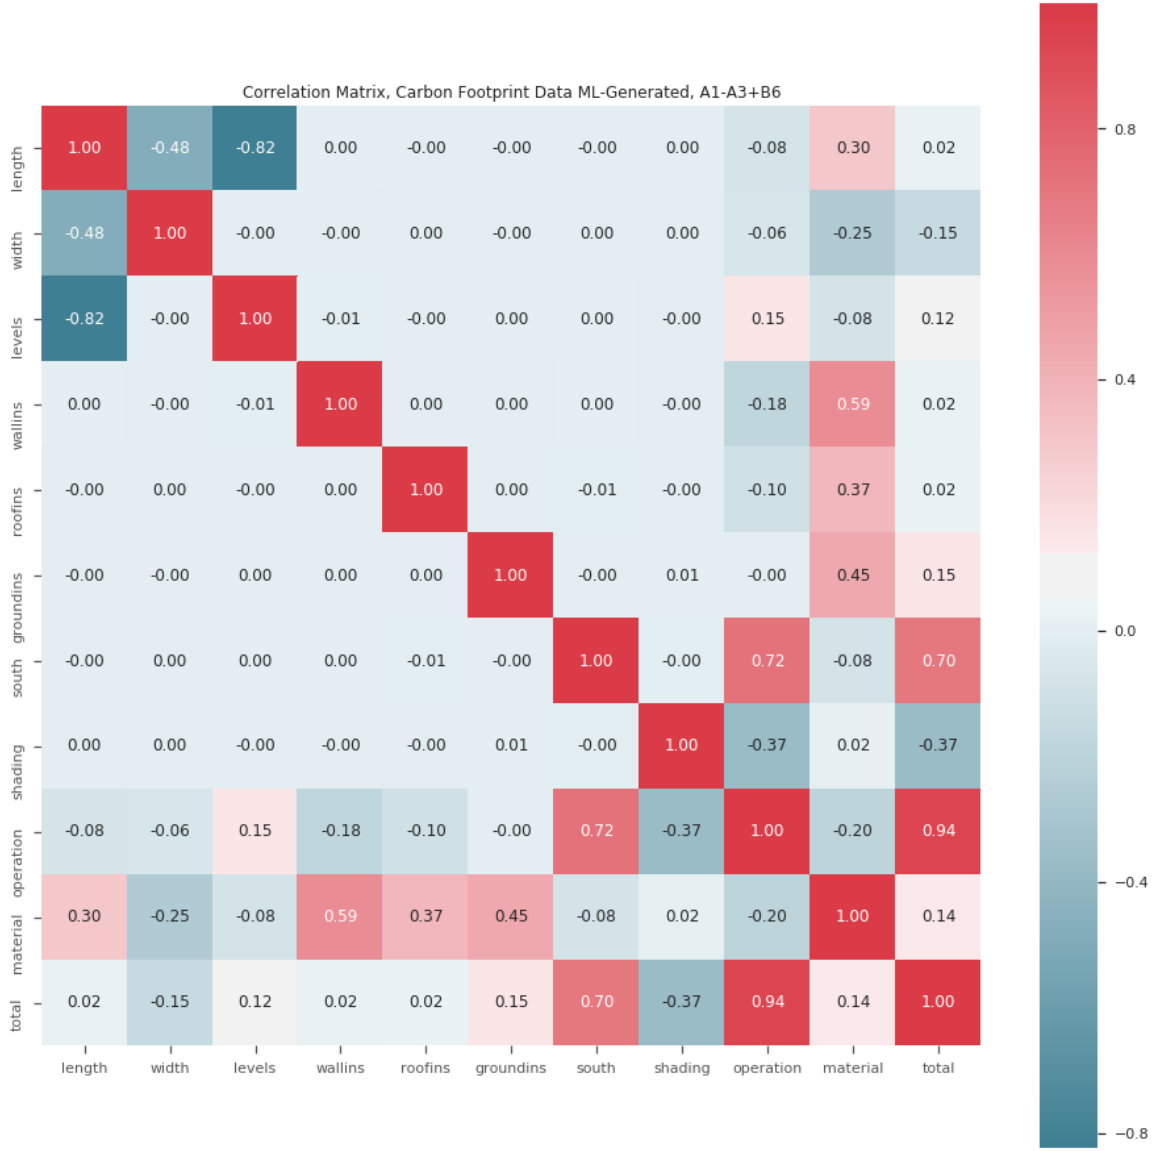

L'écart-type

📊 Écart-type : définition

👉 L'écart-type mesure la **dispersion des valeurs autour de la moyenne**.

- **Petit écart-type** → données proches de la moyenne
- **Grand écart-type** → données très dispersées

🧮 Formule de calcul

$$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

📌 À retenir

- L'écart-type = **racine de la variance**
- Toujours **positif**
- Très utilisé pour comprendre la **variabilité des données**

🧩 Étapes de calcul

1. **Calculer la moyenne**

   $\bar{x}$

2. **Calculer les écarts à la moyenne**

   $x_i - \bar{x}$

3. **Élever au carré**

   $(x_i - \bar{x})^2$

4. **Faire la moyenne des carrés**

   👉 variance

5. **Prendre la racine carrée**

   👉 écart-type

Exemples d'écart-type

Données : **5, 12, 25**

1. Moyenne :

$$\bar{x} = \frac{5 + 12 + 25}{3} = 14$$

2. Écarts :

$$-9,\ -2,\ +11$$

3. Carrés :

$$81,\ 4,\ 121$$

4. Variance :

$$\frac{81 + 4 + 121}{3} = \frac{206}{3} \approx 68{,}67$$

5. Écart-type :

$$\sigma \approx 8{,}29$$

👉 **Interprétation** : données très dispersées

Données : **10, 12, 14**

1. Moyenne :

$$\bar{x} = \frac{10 + 12 + 14}{3} = 12$$

2. Écarts :

$$-2,\ 0,\ +2$$

3. Carrés :

$$4,\ 0,\ 4$$

4. Variance :

$$\frac{4 + 0 + 4}{3} = \frac{8}{3} \approx 2{,}67$$

5. Écart-type :

$$\sigma \approx 1{,}63$$

👉 **Interprétation** : données assez proches de la moyenne

Corrélation vs causalité

La **corrélation** et la **causalité** sont deux notions liées mais très différentes :

🔗 Corrélation

La corrélation signifie qu'il existe une **relation statistique** entre deux variables : elles évoluent ensemble.

- Exemple : quand les ventes de glaces augmentent, les noyades augmentent aussi.
- Cela veut dire qu'il y a un lien, mais **sans expliquer pourquoi**.

👉 Important : une corrélation peut être **positive**, **négative**, ou même due au hasard.

⚡ Causalité

La causalité signifie qu'une variable **provoque directement** un effet sur une autre.

- Exemple : fumer augmente le risque de cancer.
- Ici, il y a un **lien de cause à effet** clairement établi.

🧠 Différence clé

- **Corrélation** = deux choses varient ensemble
- **Causalité** = une chose **cause** l'autre

👉 Une corrélation **n'implique pas** forcément une causalité.

Inférence statistique

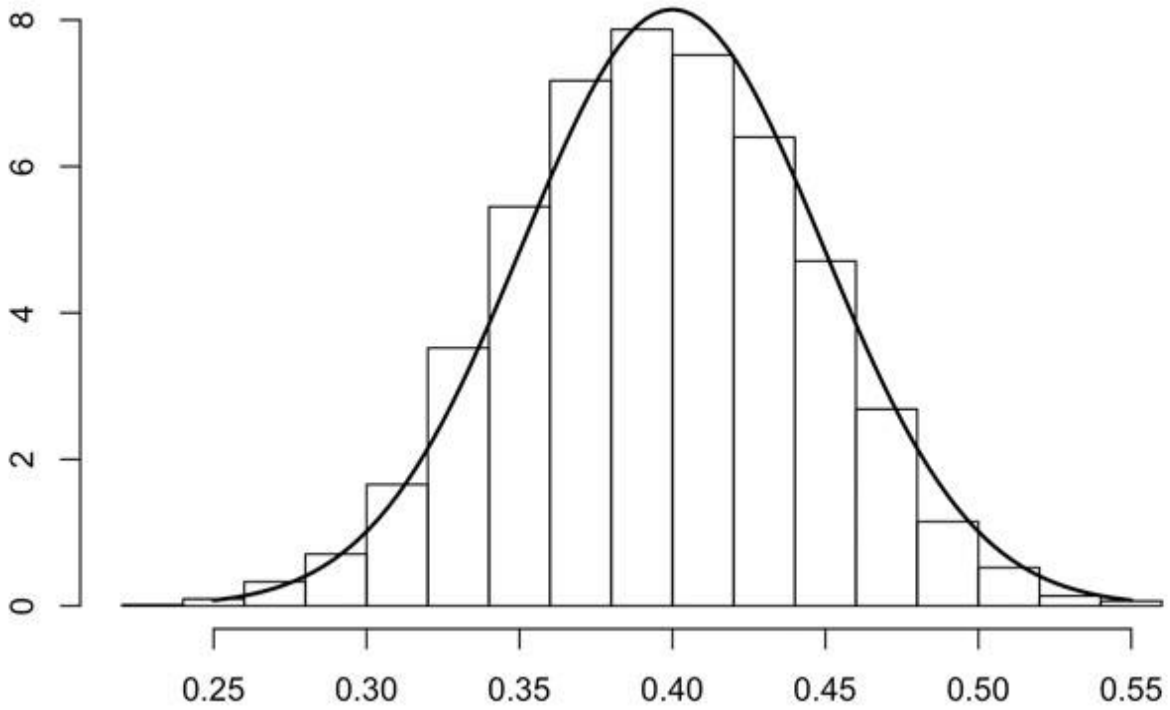

📊 Techniques d'inférence statistique

🎯 Objectif

Généraliser des résultats d'un **échantillon** à une **population**

🔑 Principales méthodes

- **Estimation**
  → moyenne, proportion, intervalle de confiance
- **Tests d'hypothèses**
  → t-test, chi², p-value
- **Régression**
  → linéaire (relation), logistique (probabilité)
- **Corrélation**
  → force du lien entre variables
- **ANOVA**
  → comparaison de plusieurs groupes
- **Méthodes bayésiennes**
  → mise à jour avec le théorème de Bayes

⚠️ À retenir

> Toujours tenir compte de l'incertitude et de la qualité des données